

Analisi della Diffusione degli Host Airbnb a Venezia

Riccardo Pati

2026-06-04

Contents

1	Grafici esplorativi	2
2	Bass Standard	4
2.1	Diagnostica Bass Standard	5
3	Bass Generalizzato con shock rettangolare	6
3.1	Diagnostica Bass Generalizzato con shock rettangolare	7
4	Bass Generalizzato con shock esponenziale	9
4.1	Diagnostica Bass Generalizzato con shock esponenziale	10
5	GGM	12
5.1	Diagnostica GGM	13
6	Confronto tra modelli	15
7	Validazione: stima su 2009–2021, verifica su 2022–2025	16
7.1	Stima dei modelli sull’insieme di stima	17
7.2	Previsioni sull’insieme di verifica	17
7.3	Errori di previsione	19
8	Previsioni out-of-sample	21
9	Affinamento ARMAX	22
9.1	Diagnostica ARMAX	23
9.2	Previsioni OOS con ARMAX	25
10	Modello Prophet	26
10.1	Preparazione dei dati	26
10.2	Stima e previsione	27
10.3	Diagnostica Prophet	27
10.4	Confronto con i modelli di diffusione	29
11	Conclusioni	30

```
library(tidyverse)
library(lubridate)
library(scales)
library(here)
library(DIMORA)
library(forecast)
library(prophet)
```

```
load(here("dati", "airbnb_pulito.Rdata"))
load(here("dati", "airroi_pulito.Rdata"))
```

1 Grafici esplorativi

L'analisi prende come unità di osservazione gli **host locali** (soggetti residenti nel Comune di Venezia che hanno aperto almeno un annuncio su Airbnb) ricostruendone la storia di iscrizione anno per anno. Due grafici complementari permettono di leggere il fenomeno su scale diverse: la curva cumulata rivela la forma strutturale del processo, quella istantanea ne evidenzia la velocità in ogni singolo anno.

```
# Dato base condiviso
host_locale_base <- airbnb_pulito %>%
  mutate(data_iscrizione = as.Date(host_since, origin = "1970-01-01")) %>%
  filter(!is.na(data_iscrizione), host_is_local == 1)


#Cumulata
p1c <- host_locale_base %>%
  count(data_iscrizione) %>%
  arrange(data_iscrizione) %>%
  mutate(host_cumulati = cumsum(n)) %>%
  ggplot(aes(data_iscrizione, host_cumulati)) +
  geom_area(fill = pal_venezia[2], alpha = 0.25) +
  geom_line(color = pal_venezia[1], linewidth = 1.2) +
  scale_y_continuous(limits = c(0, NA), labels = comma_format()) +
  labs(
    title = "Crescita cumulata degli host locali nel tempo",
    subtitle = "La forma a S e' il segnale di un processo di diffusione",
    x = NULL, y = "Host cumulati", caption = cap_inside
  ) +
  tema_venezia

#Istantanea annuale
pli <- host_locale_base %>%
  mutate(anno = year(data_iscrizione)) %>%
  count(anno) %>%
  ggplot(aes(anno, n)) +
  geom_col(fill = pal_venezia[3], alpha = 0.85, width = 0.7) +
  geom_line(color = pal_venezia[1], linewidth = 1.0) +
  geom_point(color = pal_venezia[1], size = 2.5, shape = 21,
    fill = pal_venezia[3], stroke = 1.2) +
  scale_x_continuous(breaks = scales::pretty_breaks(n = 8)) +
  scale_y_continuous(labels = comma_format()) +
  labs(
    title = "Nuovi host locali per anno",
    subtitle = "Picco di iscrizioni e successivo rallentamento post-pandemia",
    x = NULL, y = "Nuovi host", caption = cap_inside
  ) +
  tema_venezia

p1c
```

Crescita cumulata degli host locali nel tempo


La forma a S e' il segnale di un processo di diffusione



p1i

Nuovi host locali per anno

Picco di iscrizioni e successivo rallentamento post-pandemia




La curva cumulata disegna una **forma a S** caratteristica: crescita lenta nella fase di lancio (prima metà degli anni 2010), accelerazione marcata nel periodo 2014–2018 coincidente con il boom del turismo lagunare, quindi una decelerazione evidente dopo il 2019. L'istantanea conferma il picco di nuove iscrizioni collocato tra il 2016 e il 2018, seguito da un crollo netto nel 2020–2021 imputabile alla pandemia COVID-19, che ha di fatto azzerato la domanda turistica a Venezia per due stagioni consecutive. Questi elementi sono i segnali diagnostici che giustificano l'applicazione di un modello di diffusione di tipo Bass.

2 Bass Standard

```
n_host <- host_locale_base %>%
  mutate(anno = year(data_iscrizione)) %>%
  count(anno) %>% pull(n)

bm_host <- BM(n_host, display = T)
```



```
summary(bm_host)

## Call: ( Standard Bass Model )
##
## BM(series = n_host, display = T)
##
## Residuals:
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -169.27  -64.26   -25.05   -16.18   40.72   100.06
##
## Coefficients:
##      Estimate Std. Error    Lower    Upper p-value
## m 3.304973e+03 51.710840124 3.203621e+03 3.406324e+03 1.14e-18 ***
## p 1.861681e-02  0.002725313 1.327529e-02 2.395832e-02 8.18e-06 ***
## q 4.467250e-01  0.033529687 3.810080e-01 5.124420e-01 2.42e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error 86.98769 on 14 degrees of freedom
## Multiple R-squared:  0.998659 Residual sum of squares: 105936
```

Il modello stima tre parametri: il potenziale di mercato m , il coefficiente di innovazione $p = 0.019$ e il coefficiente di imitazione $q = 0.447$. Tutti e tre risultano statisticamente significativi, confermando che il

processo di adozione è identificabile nei dati.

Il confronto tra p e q , con $p \ll q$, indica una dinamica prevalentemente **imitativa**: i nuovi host si iscrivono principalmente dopo aver osservato il comportamento di host già attivi, non per effetto di comunicazione esterna (pubblicità, media). Questo è coerente con la natura di Airbnb, piattaforma in cui il passaparola e la visibilità dei vicini che affittano costituisce il principale canale di diffusione.

L' R^2 elevato (calcolato sui dati cumulati) non è di per sé informativo: la natura monotona della cumulata rende quasi qualunque modello con trend crescente capace di ottenere un buon fit su questa scala. La diagnostica reale va condotta sui **residui dei dati istantanei**.


2.1 Diagnostica Bass Standard

```
# Ricava l'indice temporale per mappare anni → t
tabella_anni <- host_locale_base %>%
  mutate(anno = year(data_iscrizione)) %>%
  count(anno) %>%
  mutate(t = row_number())


# Confronto grafico Bass Standard: fitted vs osservati
fit_bm_inst <- make_instantaneous(fitted(bm_host))

anni_seq <- tabella_anni$anno

plot(anni_seq, n_host, type = "b", pch = 16, lty = 3, cex = 0.7,
      xlab = "Anno", ylab = "Nuovi host locali",
      main = "Bass Standard: fitted vs osservati")
lines(anni_seq, fit_bm_inst, lwd = 2, col = "red")
```




```
# ACF dei residui
acf(residuals(bm_host), main = "ACF residui - Bass Standard")
```



Il confronto tra curva stimata e dati osservati rivela un **sistematico sottostima nella fase iniziale** (2009–2013): il modello di Bass standard presuppone che le prime adozioni avvengano esclusivamente per innovazione esogena a ritmo costante p , mentre nella realtà le iscrizioni si concentrano in un sottoinsieme di pionieri con caratteristiche specifiche. L'ACF dei residui indica la presenza di **autocorrelazione positiva ai primi ritardi**, segno che il modello non cattura tutta la struttura dinamica della serie.

3 Bass Generalizzato con shock rettangolare

```
GBMr1_host <- GBM(n_host, shock = "rett", nshock = 1,
  prelimestimates = c(coef(bm_host)[1], coef(bm_host)[2], coef(bm_host)[3], 3, 9, -0.1))
```



```
summary(GBMr1_host)
```

```
## Call: ( Generalized Bass model with 1 Rectangular shock )
##
##   GBM(series = n_host, shock = "rett", nshock = 1, prelimestimates = c(coef(bm_host)[1],
##     coef(bm_host)[2], coef(bm_host)[3], 3, 9, -0.1))
##
## Residuals:
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -98.434 -47.034  -6.934  -9.975  28.212  48.660
##
## Coefficients:
##           Estimate   Std. Error   Lower   Upper   p-value
## m    3382.90351613  53.013932824  3.278998e+03  3486.80891515  1.73e-15 ***
## p         0.01092591  0.002400073  6.221854e-03   0.01562997  8.27e-04 ***
## q         0.59414000  0.059933585  4.766723e-01   0.71160766  8.06e-07 ***
## a1         6.40118261  0.431925691  5.554624e+00   7.24774140  1.29e-08 ***
## b1        13.99999950  1.446410202  1.116509e+01  16.83491140  1.02e-06 ***
## c1        -0.37902545  0.068098352 -5.124958e-01  -0.24555513  1.69e-04 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error 55.81485 on 11 degrees of freedom
## Multiple R-squared:  0.998603 Residual sum of squares: 34268.27
```


3.1 Diagnostica Bass Generalizzato con shock rettangolare

```
fit_gbmr_inst <- make.instantaneous(fitted(GBMr1_host))
plot(anni_seq, n_host, type = "b", pch = 16, lty = 3, cex = 0.7,
```

```

xlab = "Anno", ylab = "Nuovi host locali", ylim = c(0,500),
main = "GBM rettangolare: fitted vs osservati")
lines(anni_seq, fit_gbm_inst, lwd = 2, col = 2)
lines(anni_seq, fit_bm_inst, lwd = 2, col = 3, lty = 2)
legend("topright", c("GBM rettangolare", "Bass Standard"),
      col = c(2, 3), lty = c(1, 2), lwd = 2, bty = "n")


```



```

acf(residuals(GBMr1_host), main = "ACF residui - GBM rettangolare")

```





Il GBM con impulso rettangolare introduce una **perturbazione temporanea** sul potenziale di mercato nell'intervallo $[2011, 2017]$, scalandolo di un fattore $(1 + c_1)$. La significatività del parametro c_1 conferma che lo shock è statisticamente identificabile nei dati: il modello riconosce una discontinuità nel ritmo di adozione nell'arco temporale specificato.

Il fit visivo sulle istantanee mostra un miglioramento rispetto al Bass standard, in particolare nella zona di perturbazione. Tuttavia, la natura dell'impulso rettangolare, attivo in modo uniforme per tutta la durata $[a, b]$ e poi completamente assente, lo rende poco adatto a descrivere shock con intensità variabile nel tempo, come la crisi pandemica che ha avuto un effetto più acuto nel primo anno (2020) rispetto al secondo (2021). L'ACF dei residui permette di valutare se la struttura dinamica residua è stata ridotta rispetto al Bass standard.

4 Bass Generalizzato con shock esponenziale

```
GBMe1_host <- GBM(n_host, shock = "exp", nshock = 1,
  prelimestimates = c(coef(bm_host)[1], coef(bm_host)[2], coef(bm_host)[3], 2, -0.4, 0.3))
```



```
summary(GBMe1_host)
```

```
## Call: ( Generalized Bass model with 1 Exponential shock )
##
## GBM(series = n_host, shock = "exp", nshock = 1, prelimestimates = c(coef(bm_host)[1],
##   coef(bm_host)[2], coef(bm_host)[3], 2, -0.4, 0.3))
##
## Residuals:
##      Min.      1st Qu.      Median      Mean      3rd Qu.      Max.
## -49.2018 -12.0640  -1.9260  -0.5699   9.2479  46.4579
##
## Coefficients:
##      Estimate      Std. Error      Lower      Upper      p-value
## m    3747.02044162  270.34857594 3217.14696951 4.276894e+03 2.61e-08 ***
## p      0.00556061   0.00364569  -0.00158481 1.270603e-02 1.55e-01
## q      0.04612827   0.04842371  -0.04878045 1.410370e-01 3.61e-01
## a1     2.47990789   0.26592295   1.95870849 3.001107e+00 1.48e-06 ***
## b1    -0.12642447   0.09565521  -0.31390523 6.105630e-02 2.13e-01
## c1    10.31161608   8.31941114  -5.99413012 2.661736e+01 2.41e-01
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error 31.6763 on 11 degrees of freedom
## Multiple R-squared:  0.99955 Residual sum of squares: 11037.27
```


4.1 Diagnostica Bass Generalizzato con shock esponenziale

```
fit_gbme_inst <- make.instantaneous(fitted(GBMe1_host))
plot(anni_seq, n_host, type = "b", pch = 16, lty = 3, cex = 0.7,
```

```

xlab = "Anno", ylab = "Nuovi host locali",
main = "GBM esponenziale: fitted vs osservati")
lines(anni_seq, fit_gbme_inst, lwd = 2, col = 2)
lines(anni_seq, fit_bm_inst, lwd = 2, col = 3, lty = 2)
legend("topright", c("GBM esponenziale", "Bass Standard"),
      col = c(2, 3), lty = c(1, 2), lwd = 2, bty = "n")


```



```

acf(residuals(GBMe1_host), main = "ACF residui - GBM esponenziale")

```




Il GBM con shock esponenziale modella una perturbazione che nasce al tempo a con intensità c e decade poi con velocità $|b|$ (memoria dello shock). La non-significatività di p e q non è un segnale di cattivo modello: quando lo shock esponenziale è attivo fin dai primi periodi, esso assorbe parte della struttura di innovazione e imitazione, rendendo difficile la separazione dei contributi. Il coefficiente $b < 0$ conferma che l'effetto della perturbazione si riduce nel tempo, compatibile con una crisi transitoria.

A livello grafico il modello descrive meglio la traiettoria nella fase iniziale e nella zona di decelerazione post-picco. La sua principale limitazione è l'**instabilità delle stime** di m , p e q : con parametri non significativi, le previsioni OOS di lungo periodo risultano meno affidabili.

5 GGM

```
# Il GGM introduce un potenziale di mercato dinamico tramite due canali
# di comunicazione aggiuntivi (p_c, q_c), catturando meglio la fase iniziale
# della curva senza ricorrere a uno shock esterno
# Ordine prelimestimates: m, p_c, q_c, p, q
ggm_host <- GGM(n_host,
  prelimestimates = c(coef(bm_host)[1], 0.01, 0.01,
    coef(bm_host)[2], coef(bm_host)[3]))
```



```
summary(ggm_host)
```


```
## Call: ( Guseo Guidolin Model )
##
##   GGM(series = n_host, prelimestimates = c(coef(bm_host)[1], 0.01,
##     0.01, coef(bm_host)[2], coef(bm_host)[3]))
##
## Residuals:
##      Min. 1st Qu.  Median      Mean 3rd Qu.     Max.
## -57.184 -17.213 -13.984  -3.087  19.989  51.077
##
## Coefficients:
##              Estimate      Std.Error      Lower      Upper  p-value
## K      3.466507e+03  73.025295110  3.323380e+03  3.609634e+03  4.99e-15 ***
## pc      1.600773e-02   0.006156801  3.940617e-03  2.807484e-02  2.32e-02  *
## qc      3.221983e-01   0.064082721  1.965985e-01  4.477981e-01  2.95e-04 ***
## ps      2.563304e-02   0.006985893  1.194094e-02  3.932514e-02  3.21e-03  **
## qs      7.790855e-01   0.131161818  5.220130e-01  1.036158e+00  6.82e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error  39.58694  on  12  degrees of freedom
## Multiple R-squared:  0.999234  Residual sum of squares:  18805.51
```

5.1 Diagnostica GGM


```
fit_ggm_inst <- make.instantaneous(fitted(ggm_host))

plot(anni_seq, n_host, type = "b", pch = 16, lty = 3, cex = 0.7,
     xlab = "Anno", ylab = "Nuovi host locali", ylim = c(0, 500),
     main = "GGM: fitted vs osservati")
lines(anni_seq, fit_ggm_inst, lwd = 2, col = 2)
```

```
lines(anni_seq, fit_bm_inst, lwd = 2, col = 3, lty = 2)
legend("topright", c("GGM", "Bass Standard"),
      col = c(2, 3), lty = c(1, 2), lwd = 2, bty = "n")
```



```
acf(residuals(ggm_host), main = "ACF residui - GGM")
```



Il GGM estende il Bass standard introducendo un **potenziale di mercato dinamico**: oltre ai canali

individuali (p, q) , il modello aggiunge due canali di comunicazione collettiva (p_c, q_c) che accelerano o frenano la diffusione attraverso i media e il passaparola aggregato.

La significatività di q_c conferma un meccanismo imitativo a livello di comunicazione, plausibile per Airbnb Venezia: l'effetto notizia ha amplificato la consapevolezza della piattaforma in modo discontinuo nel tempo.

Il miglioramento del fit nella fase iniziale rispetto al Bass standard è atteso: i parametri p_c e q_c permettono al modello di allocare più massa probabilistica nei periodi di lancio. Se i parametri di comunicazione risultano non significativi, il GGM collassa al Bass standard e la complessità aggiuntiva non è giustificata dai dati. L'ACF dei residui è il criterio finale per scegliere tra i due.

6 Confronto tra modelli

I modelli stimati si confrontano su due indicatori calcolati sulle **serie istantanee** (più informative delle cumulate per valutare l'aderenza al dato osservato anno per anno):

- **R^2_{parziale}** rispetto al Bass: quantifica il guadagno **marginale** introdotto dai parametri aggiuntivi di ciascun modello rispetto al Bass standard, calcolato come

$$\tilde{R}^2 = \frac{R^2_{\text{modello}} - R^2_{\text{Bass}}}{1 - R^2_{\text{Bass}}}$$

```
# Helper: R² istantaneo
r2_inst <- function(model, data) {
  fit <- make.instantaneous(fitted(model))
  ss_r <- sum((data - fit)^2)
  ss_t <- sum((data - mean(data))^2)
  round(1 - ss_r / ss_t, 4)
}

# Helper: R² cumulato
r2_cum <- function(model, data) {
  fit_c <- as.numeric(fitted(model))
  cum_o <- cumsum(data)
  ss_r <- sum((cum_o - fit_c)^2)
  ss_t <- sum((cum_o - mean(cum_o))^2)
  round(1 - ss_r / ss_t, 4)
}

# Calcolo
r2i_bass <- r2_inst(bm_host, n_host) # 0.8133
r2i_gbmr <- r2_inst(GBMr1_host, n_host) # 0.8839
r2i_gbme <- r2_inst(GBMe1_host, n_host) # 0.9498
r2i_ggm <- r2_inst(ggm_host, n_host) # 0.9212

r2c_bass <- r2_cum(bm_host, n_host)
r2c_gbmr <- r2_cum(GBMr1_host, n_host)
r2c_gbme <- r2_cum(GBMe1_host, n_host)
r2c_ggm <- r2_cum(ggm_host, n_host)

# R² parziale rispetto al Bass (base di riferimento)
r2p_gbmr <- round((r2i_gbmr - r2i_bass) / (1 - r2i_bass), 4) # 0.3781
r2p_gbme <- round((r2i_gbme - r2i_bass) / (1 - r2i_bass), 4) # 0.7311
r2p_ggm <- round((r2i_ggm - r2i_bass) / (1 - r2i_bass), 4) # 0.5779

# Tabella comparativa
```

```

r2_tabella <- data.frame(
  Modello      = c("Bass Standard",
                   "GBM - Shock Rettangolare",
                   "GBM - Shock Esponenziale",
                   "GGM (Guseo-Guidolin)"),
  R2_cum       = c(r2c_bass, r2c_gbmr, r2c_gbme, r2c_ggm),
  R2_ist       = c(r2i_bass, r2i_gbmr, r2i_gbme, r2i_ggm),
  R2_parz      = c("-", r2p_gbmr, r2p_gbme, r2p_ggm)
)

knitr::kable(
  r2_tabella,
  col.names = c("Modello",
                "$R^2$ (cumulato)",
                "$\\tilde{R}^2$ (istantaneo)",
                "$\\tilde{R}^2$ parziale vs Bass"),
  align = "lccc",
  digits = 4,
  escape = FALSE,
  caption = "Confronto tra modelli di diffusione"
)

```

Table 1: Confronto tra modelli di diffusione

Modello	R^2 (cumulato)	$\tilde{R}^2$ (istantaneo)	$\tilde{R}^2$ parziale vs Bass
Bass Standard	0.9957	0.8133	-
GBM – Shock Rettangolare	0.9986	0.8839	0.3781
GBM – Shock Esponenziale	0.9996	0.9498	0.7311
GGM (Guseo-Guidolin)	0.9992	0.9212	0.5779

Il **GBM esponenziale** ottiene il miglior R^2 istantaneo (0.9498) e il più alto R^2_{parziale} (0.7311), indicando che lo shock esponenziale recupera il 73% della varianza residua del Bass. Il **GGM** raggiunge $R^2 = 0.9212$ con soli 5 parametri tutti significativi, costituendo il miglior compromesso tra fit e parsimonia. Il **GBM rettangolare** migliora il Bass in modo più modesto ($R^2_{\text{parz}} = 0.3781$), ma mantiene la piena significatività statistica di tutti i coefficienti.

7 Validazione: stima su 2009–2021, verifica su 2022–2025

L'analisi in-sample (R^2) valuta quanto i modelli aderiscono ai dati su cui sono stati stimati — una misura di fit, non di capacità previsiva. Per testare quest'ultima si divide la serie in due blocchi:

- **Stima** (2009–2021, $T_s = 13$ osservazioni): include la fase di lancio, il picco e il crollo pandemico; i modelli vengono ri-stimati su questo solo sottoinsieme.
- **Verifica** (2022–2025, $T_v = 4$ osservazioni): anni non visti durante la stima, sui quali si calcolano gli errori di previsione.

La scelta del punto di taglio al 2021 è intenzionale: il periodo di verifica è interamente post-pandemico, il che permette di valutare se i modelli, stimati *includendo* lo shock COVID, riescono a proiettare correttamente la ripresa parziale e il successivo rallentamento.

7.1 Stima dei modelli sull'insieme di stima

```
# Definizione dei blocchi
anno_cut <- 2021
T_s      <- sum(anni_seq <= anno_cut)      # 13 (2009-2021)
T_v      <- length(n_host) - T_s          # 4  (2022-2025)

n_stima  <- n_host[seq_len(T_s)]
n_verif  <- n_host[(T_s + 1):length(n_host)]
anni_stima <- anni_seq[seq_len(T_s)]
anni_verif <- anni_seq[(T_s + 1):length(anni_seq)]

# Re-stima su n_stima
bm_sv    <- BM(n_stima, display = FALSE)
GBMr_sv  <- GBM(n_stima, shock = "rett", nshock = 1,
               prelimestimates = c(coef(bm_sv)[1], coef(bm_sv)[2],
                                   coef(bm_sv)[3], 3, 9, -0.1),
               display = FALSE)
GBMe_sv  <- GBM(n_stima, shock = "exp", nshock = 1,
               prelimestimates = c(coef(bm_sv)[1], coef(bm_sv)[2],
                                   coef(bm_sv)[3], 2, -0.4, 0.3),
               display = FALSE)
ggm_sv   <- GGM(n_stima,
               prelimestimates = c(coef(bm_sv)[1], 0.01, 0.01,
                                   coef(bm_sv)[2], coef(bm_sv)[3]),
               display = FALSE)

# Riepilogo parametri stimati
cat("  Bass (stima)  \n"); print(round(coef(bm_sv), 5))

##      Bass (stima)

##           m           p           q
## 3093.54167    0.01519    0.52651

cat("  GGM (stima)  \n"); print(round(coef(ggm_sv), 5))

##      GGM (stima)

##           K           pc           qc           ps           qs
## 3151.67538    0.00473    0.55930    0.01281    1.32423
```

7.2 Previsioni sull'insieme di verifica

```
# Previsioni istantanee per l'intero orizzonte (stima + verifica)
T_tot <- T_s + T_v # 17

pred_bm_v    <- tail(make.instantaneous(predict(bm_sv, newx = 1:T_tot)), T_v)
pred_gbmr_v  <- tail(make.instantaneous(predict(GBMr_sv, newx = 1:T_tot)), T_v)
pred_gbme_v  <- tail(make.instantaneous(predict(GBMe_sv, newx = 1:T_tot)), T_v)
pred_ggm_v   <- tail(make.instantaneous(predict(ggm_sv, newx = 1:T_tot)), T_v)

# Grafico: fitted in-sample + previsioni OOS a confronto con osservati
fit_bm_s    <- make.instantaneous(fitted(bm_sv))
fit_ggm_s    <- make.instantaneous(fitted(ggm_sv))
```

```

ylim_v <- c(0, max(n_host) * 1.1)

plot(anni_stima, n_stima,
     type = "b", pch = 16, lty = 3, cex = 0.8, col = 1,
     xlim = c(min(anni_seq), max(anni_verif)),
     ylim = ylim_v,
     xlab = "Anno", ylab = "Nuovi host locali",
     main = "Stima vs verifica: tutti i modelli")

# osservati verifica
points(anni_verif, n_verif, pch = 17, cex = 1, col = 1)


# linea di taglio
abline(v = anno_cut + 0.5, lty = 2, col = "grey50")

# fitted in-sample (solo GGM per leggibilità)
lines(anni_stima, fit_ggm_s, lwd = 1.5, col = pal_venezia[3], lty = 2)
lines(anni_stima, fit_bm_s, lwd = 1.5, col = "grey60", lty = 2)

# previsioni verifica
lines(anni_verif, pred_bm_v, lwd = 2, col = "grey60", lty = 1)
lines(anni_verif, pred_gbm_v, lwd = 2, col = pal_venezia[5], lty = 1)
lines(anni_verif, pred_gbme_v, lwd = 2, col = pal_venezia[6], lty = 1)
lines(anni_verif, pred_ggm_v, lwd = 2, col = pal_venezia[3], lty = 1)

legend("topright",
      legend = c("Osservati (stima)", "Osservati (verifica)",
                  "Bass", "GBM rett.", "GBM exp.", "GGM"),
      col = c(1, 1, "grey60", pal_venezia[5], pal_venezia[6], pal_venezia[3]),
      pch = c(16, 17, NA, NA, NA, NA),
      lty = c(NA, NA, 1, 1, 1, 1),
      lwd = c(NA, NA, 2, 2, 2, 2),
      bty = "n", cex = 0.75)

```



7.3 Errori di previsione

```
# Metriche
mae_ <- function(o, p) mean(abs(o - p))
rmse_ <- function(o, p) sqrt(mean((o - p)^2))
mape_ <- function(o, p) mean(abs((o - p) / o)) * 100

# Previsioni anno per anno (tabella dettaglio)
detail <- data.frame(
  Anno = anni_verif,
  Osserv. = n_verif,
  Bass = round(pred_bm_v),
  GBM_r = round(pred_gbm_r_v),
  GBM_e = round(pred_gbme_v),
  GGM = round(pred_ggm_v)
)

knitr::kable(detail,
  col.names = c("Anno", "Osservato", "Bass", "GBM rett.", "GBM exp.", "GGM"),
  align = "ccccc",
  caption = "Previsioni vs osservati nel periodo di verifica (2022-2025)")
```

Table 2: Previsioni vs osservati nel periodo di verifica (2022-2025)

Anno	Osservato	Bass	GBM rett.	GBM exp.	GGM
2022	96	38	22	42	49
2023	137	23	10	25	29
2024	80	13	4	15	17
2025	35	8	2	9	10

```

# Tabella riassuntiva degli errori
err_tab <- data.frame(
  Modello = c("Bass Standard",
              "GBM - Shock Rettangolare",
              "GBM - Shock Esponenziale",
              "GGM (Guseo-Guidolin)",
  MAE = c(mae_(n_verif, pred_bm_v),
          mae_(n_verif, pred_gbmr_v),
          mae_(n_verif, pred_gbme_v),
          mae_(n_verif, pred_ggm_v)),
  RMSE = c(rmse_(n_verif, pred_bm_v),
           rmse_(n_verif, pred_gbmr_v),
           rmse_(n_verif, pred_gbme_v),
           rmse_(n_verif, pred_ggm_v)),
  MAPE = c(mape_(n_verif, pred_bm_v),
           mape_(n_verif, pred_gbmr_v),
           mape_(n_verif, pred_gbme_v),
           mape_(n_verif, pred_ggm_v))
)

# Evidenzio il miglior modello per ogni metrica
best <- apply(err_tab[, -1], 2, which.min)

knitr::kable(
  err_tab,
  col.names = c("Modello", "MAE", "RMSE", "MAPE (%)"),
  digits = 2,
  align = "lccc",
  caption = "Errori di previsione sul periodo di verifica (2022-2025)"
)

```

Table 3: Errori di previsione sul periodo di verifica (2022–2025)

Modello	MAE	RMSE	MAPE (%)
Bass Standard	66.35	73.33	75.99
GBM – Shock Rettangolare	77.61	84.49	89.90
GBM – Shock Esponenziale	64.02	71.09	73.01
GGM (Guseo-Guidolin)	61.13	68.27	70.06

Il **MAE** misura l'errore medio assoluto in unità (nuovi host/anno); il **RMSE** penalizza maggiormente gli errori grandi; il **MAPE** esprime l'errore in percentuale del valore osservato ed è utile per confrontare modelli su scale diverse.

Da notare che con soli $T_v = 4$ anni di verifica le stime degli errori hanno varianza elevata: una singola osservazione anomala può spostare sensibilmente le classifiche. Le metriche vanno interpretate come indicazioni di tendenza, non come ranking definitivi.

Inoltre, non è stata considerata questa una metrica corretta per via della risalita che i modelli non riescono a prevedere.

8 Previsioni out-of-sample

```
T_oss <- length(n_host)           # ultimo periodo osservato
T_oos <- T_oss + 5                 # orizzonte: 5 anni oltre l'ultimo dato

pred_bm   <- make.instantaneous(predict(bm_host,   newx = 1:T_oss))
pred_gbmr <- make.instantaneous(predict(GBMr1_host, newx = 1:T_oss))
pred_gbme <- make.instantaneous(predict(GBMe1_host, newx = 1:T_oss))
pred_ggm  <- make.instantaneous(predict(ggm_host,  newx = 1:T_oss))

# Asse x con gli anni reali (osservati + futuri)
ultimo_anno <- max(tabella_anni$anno)
anni_oos    <- c(anni_seq, seq(ultimo_anno + 1, by = 1, length.out = 5))


# Grafico confronto OOS
plot(anni_seq, n_host,
     type = "b", pch = 16, lty = 3, cex = 0.7, col = 1,
     xlim = c(min(anni_seq), max(anni_oos)),
     ylim = c(0, max(n_host) * 1.2),
     xlab = "Anno", ylab = "Nuovi host locali",
     main = "Previsioni out-of-sample: confronto tra modelli")

abline(v = ultimo_anno + 0.5, lty = 2, col = "grey60") # linea di confine OOS

lines(anni_oos, pred_bm,   lwd = 2, col = 2,          lty = 2)
lines(anni_oos, pred_gbmr, lwd = 2, col = 3,          lty = 1)
lines(anni_oos, pred_gbme, lwd = 2, col = 4,          lty = 1)
lines(anni_oos, pred_ggm,  lwd = 2, col = pal_venezia[3], lty = 1)

legend("topright",
      legend = c("Osservati", "Bass Standard",
                  "GBM rettangolare", "GBM esponenziale", "GGM"),
      col     = c(1, 2, 3, 4, pal_venezia[3]),
      lty     = c(NA, 2, 1, 1, 1),
      pch     = c(16, NA, NA, NA, NA),
      lwd     = c(NA, 2, 2, 2, 2),
      bty     = "n")
```

Previsioni out-of-sample: confronto tra modelli



Il grafico mette a confronto le traiettorie previste dai quattro modelli oltre l'ultimo anno osservato. Alcune considerazioni per la lettura:

- **Bass Standard** : proietta la coda discendente della curva logistica. È il punto di riferimento ma non incorpora alcuna informazione sulle perturbazioni storiche.
- **GBM rettangolare** e **GBM esponenziale**: le previsioni riflettono la forma dello shock stimato; se il periodo di shock cade interamente in-sample, le previsioni future convergono verso la curva logistica di fondo.
- **GGM**: se i canali di comunicazione sono significativi, la previsione può divergere dal Bass standard anche in fase di decelerazione.

In generale, i modelli concordano su una **traiettoria decrescente** del numero di nuovi host locali nei prossimi anni, compatibile con un mercato in saturazione e con le restrizioni normative introdotte dal Comune di Venezia sugli affitti brevi. La divergenza tra le traiettorie cresce con l'orizzonte previsivo, sottolineando l'incertezza intrinseca delle proiezioni di lungo periodo.

9 Affinamento ARMAX

L'analisi delle ACF ha mostrato autocorrelazione residua nei modelli di sola diffusione. Il modello ARMAX affronta questo problema mantenendo il GGM come **regressore esterno** per catturare il trend di diffusione, e delegando a una componente ARMA(p, q) la struttura temporale rimasta nei residui. La risposta è modellata sulla serie **cumulata** e l'ordine ARMA viene selezionato valutando l'ACF dei residui, il quale ha portato a scegliere una componente ARMA(2,1) con $d = 0$ fisso non si differenzia perché il trend è già catturato dal regressore di diffusione.

```
# Regressore esterno: fitted CUMULATI del modello base
fit_base_cum <- fitted(ggm_host)

# Stima ARMAX
armax_host <- Arima(cumsum(n_host),
                    order = c(2, 0, 1),
```

```

                                xreg = fit_base_cum)
summary(armax_host)

## Series: cumsum(n_host)
## Regression with ARIMA(2,0,1) errors
##
## Coefficients:
##          ar1          ar2          ma1  intercept          xreg
##          0.8455   -0.7042   -1.0000    -3.2551    1.0008
## s.e.    0.1587    0.1500    0.1884     4.6391    0.0022
##
## sigma^2 = 503.3:  log likelihood = -76.12
## AIC=164.25   AICc=172.65   BIC=169.25
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -1.832738 18.84898 15.77743 -16.52936 17.6262 0.07486325
##              ACF1
## Training set -0.02838866
# lambda 1 indica che la scala è coerente con i dati originali (buon segno)

```


9.1 Diagnostica ARMAX

```


pred_armax_inst <- make.instantaneous(fitted(armax_host))

# Confronto grafico: GGM vs GGM + ARMAX vs osservati
plot(anni_seq, n_host,
     type = "b", pch = 16, lty = 3, cex = 0.7, col = 1,
     xlab = "Anno", ylab = "Nuovi host locali", ylim = c(0,500),
     main = "Affinamento ARMAX: fitted vs osservati")
lines(anni_seq, fit_ggm_inst, lwd = 1.5, col = 3, lty = 2)
lines(anni_seq, pred_armax_inst, lwd = 2, col = 2)
legend("topright", c("Osservati", "GGM", "GGM + ARMAX"),
     col = c(1, 3, 2), lty = c(NA, 2, 1),
     pch = c(16, NA, NA), lwd = c(NA, 1.5, 2), bty = "n")

```



```
# ACF residui: obiettivo è avvicinarsi al white noise
acf(residuals(armax_host), main = "ACF residui - ARMAX")
```



Il confronto grafico tra GGM e GGM+ARMAX evidenzia il contributo dell'affinamento: la curva ARMAX aderisce più strettamente ai punti osservati, specialmente nei periodi in cui il GGM mostrava errori sistematici. L'ACF dei residui ARMAX non presenta autocorrelazioni significative, il modello ha catturato tutta la struttura dinamica identificabile nei dati e i residui si avvicinano al **white noise**; condizione necessaria per previsioni attendibili.

Il $\lambda \approx 1$ dell' Arima indica che la scala del regressore esterno è coerente con quella della serie risposta, senza necessità di trasformazioni.

9.2 Previsioni OOS con ARMAX

```
# Per prevedere OOS con ARMAX serve il regressore futuro.
# Usiamo le previsioni cumulate del GGM come proxy dei periodi futuri.
pred_ggm_cum_oos <- tail(predict(ggm_host, newx = 1:T_oos), 5)

pred_armax_oos <- forecast(armax_host,
                          h = 5,
                          xreg = pred_ggm_cum_oos)

# Ricostruiamo la serie istantanea completa (in-sample + OOS)
armax_cum_full <- c(as.numeric(fitted(armax_host)),
                   as.numeric(pred_armax_oos$mean))
armax_inst_full <- make.instantaneous(armax_cum_full)

# Intervalli di confidenza OOS (cumulate + istantanee con differenza)
armax_lo_inst <- make.instantaneous(
  c(as.numeric(fitted(armax_host)), as.numeric(pred_armax_oos$lower[, 2])))
armax_hi_inst <- make.instantaneous(
  c(as.numeric(fitted(armax_host)), as.numeric(pred_armax_oos$upper[, 2])))


# Grafico finale: tutti i modelli + ARMAX
plot(anni_seq, n_host,
     type = "b", pch = 16, lty = 3, cex = 0.7, col = 1,
     xlim = c(min(anni_seq), max(anni_oos)),
     ylim = c(0, max(n_host, armax_hi_inst, na.rm = TRUE) * 1.1),
     xlab = "Anno", ylab = "Nuovi host locali",
     main = "Previsioni OOS: tutti i modelli + affinamento ARMAX")

abline(v = ultimo_anno + 0.5, lty = 2, col = "grey60")

lines(anni_oos, pred_bm, lwd = 1.5, col = "grey50", lty = 2)
lines(anni_oos, pred_gbmr, lwd = 1.5, col = pal_venezia[5], lty = 1)
lines(anni_oos, pred_gbme, lwd = 1.5, col = pal_venezia[6], lty = 1)
lines(anni_oos, pred_ggm, lwd = 1.5, col = pal_venezia[3], lty = 1)
lines(anni_oos, armax_inst_full, lwd = 2.5, col = pal_venezia[1], lty = 1)

legend("topright",
      legend = c("Osservati", "Bass Standard", "GBM rettangolare",
                 "GBM esponenziale", "GGM", "GGM + ARMAX"),
      col = c(1, "grey50", pal_venezia[5],
              pal_venezia[6], pal_venezia[3], pal_venezia[1]),
      lty = c(NA, 2, 1, 1, 1, 1),
      pch = c(16, NA, NA, NA, NA, NA),
      lwd = c(NA, 1.5, 1.5, 1.5, 1.5, 2.5),
      bty = "n")
```

Previsioni OOS: tutti i modelli + affinamento ARMAX



Il grafico finale sovrappone le previsioni di tutti e cinque i modelli, mostrando il miglioramento ottenuto dall'affinamento ARMAX.

10 Modello Prophet

I modelli di diffusione applicati finora (Bass, GBM, GGM) sono **strutturali**: impongono una forma funzionale derivata da una teoria del processo di adozione. Prophet adotta una filosofia opposta, **data-driven**: scompone la serie in trend + stagionalità + punti di cambio (changepoint), senza assumere un meccanismo di diffusione. Questa flessibilità lo rende un utile termine di paragone, ma la sua interpretabilità in chiave economica è inferiore.

Due adattamenti rispetto ai modelli adattati in precedenza:

1. **Aggregazione mensile** invece che annuale. La serie annuale conta solo 17 osservazioni, insufficienti per stimare stagionalità e changepoint; aggregando per mese si ottengono 197 punti.
2. **Crescita logistica con cap ancorato al Bass**. Si modella la serie *cumulata* degli host con `growth = "logistic"`, fissando il tetto di saturazione (`cap`) pari al potenziale di mercato m stimato dal modello di Bass.

10.1 Preparazione dei dati

```
# Serie mensile dei nuovi host locali (con mesi vuoti riempiti a 0)
host_mensile <- host_locale_base %>%
  mutate(mese = floor_date(data_iscrizione, "month")) %>%
  count(mese, name = "nuovi") %>%
  arrange(mese) %>%
  complete(mese = seq(min(mese), max(mese), by = "month"),
           fill = list(nuovi = 0)) %>%
  mutate(cumulati = cumsum(nuovi))

# Tetto di saturazione: potenziale di mercato m stimato dal Bass
```

```

m_bass <- as.numeric(coef(bm_host)[1])
cap_prophet <- max(m_bass, max(host_mensile$cumulati)) * 1.05 # margine 5%

# Dataframe in formato Prophet: ds (data), y (risposta), cap (tetto)
df_prophet <- host_mensile %>%
  transmute(ds = mese, y = cumulati, cap = cap_prophet)

cat("Potenziale Bass (m):", round(m_bass),
    "| Cap Prophet:", round(cap_prophet),
    "| Ultimo cumulato osservato:", max(host_mensile$cumulati), "\n")

## Potenziale Bass (m): 3305 | Cap Prophet: 3544 | Ultimo cumulato osservato: 3375

```

10.2 Stima e previsione

```

# Crescita logistica, stagionalità annuale, changepoint automatici (default 25)
m_prophet <- prophet(df_prophet,
  growth = "logistic",
  yearly.seasonality = TRUE,
  weekly.seasonality = FALSE,
  daily.seasonality = FALSE)

# Previsione a 24 mesi (2 anni) oltre l'ultimo dato osservato
future <- make_future_dataframe(m_prophet, periods = 24, freq = "month")
future$cap <- cap_prophet
forecast_prophet <- predict(m_prophet, future)

tail(forecast_prophet[c("ds", "yhat", "yhat_lower", "yhat_upper")])

##           ds      yhat yhat_lower yhat_upper
## 216 2027-03-01 3360.110   3279.650   3446.815
## 217 2027-04-01 3425.983   3341.334   3509.448
## 218 2027-05-01 3407.423   3331.686   3494.446
## 219 2027-06-01 3451.507   3368.117   3536.037
## 220 2027-07-01 3424.950   3336.331   3502.159
## 221 2027-08-01 3443.338   3355.182   3514.871

```


10.3 Diagnostica Prophet

```


# Previsione cumulata con banda di incertezza e punti di cambio
plot(m_prophet, forecast_prophet) +
  add_changepoints_to_plot(m_prophet, threshold = 0) +
  labs(title = "Prophet: host cumulati osservati e previsti",
       x = "Anno", y = "Host cumulati") +
  tema_venezia

```

Prophet: host cumulati osservati e previsti



```
# Scomposizione: trend + stagionalità annuale
prophet_plot_components(m_prophet, forecast_prophet)
```



```
# Date dei changepoint più rilevanti (variazione di pendenza non trascurabile)
cp_rilevanti <- m_prophet$changepoints[abs(m_prophet$params$delta) > 0.01]
cp_rilevanti
```

```
## [1] "2013-06-01 GMT" "2013-12-01 GMT" "2014-06-01 GMT" "2015-01-01 GMT"
## [5] "2015-07-01 GMT" "2016-01-01 GMT" "2016-07-01 GMT" "2017-02-01 GMT"
```

```
## [9] "2017-08-01 GMT" "2018-02-01 GMT" "2018-08-01 GMT" "2019-03-01 GMT"
## [13] "2019-09-01 GMT" "2020-03-01 GMT"
```

Il grafico della previsione mostra la curva logistica vincolata al tetto **cap**: le linee verticali tratteggiate segnalano i **change point** dove Prophet rileva una variazione significativa della pendenza del trend. Ci si attende un changepoint in corrispondenza del 2020, coincidente con il blocco pandemico, e un rallentamento progressivo verso la saturazione.

La scomposizione separa il **trend** (la componente di diffusione di fondo) dalla **stagionalità annuale**, che cattura il pattern infra-annuale delle iscrizioni: gli host tendono ad attivare gli annunci in specifici mesi (tipicamente in primavera, prima della stagione turistica estiva). Questa informazione è invisibile ai modelli di diffusione strutturali, che operano su scala annuale.

10.4 Confronto con i modelli di diffusione

```
# Riporto Prophet su base annuale: cumulato a fine anno + differenza = nuovi host
prophet_annuale <- forecast_prophet %>%
  mutate(anno = year(ds)) %>%
  group_by(anno) %>%
  summarise(cum_fine = last(yhat), .groups = "drop") %>%
  mutate(nuovi_prophet = cum_fine - lag(cum_fine, default = 0))


# Allineo l'asse temporale con gli altri modelli (osservati + OOS)
prophet_su_grid <- prophet_annuale %>%
  filter(anno %in% anni_oos) %>%
  arrange(anno)

# Grafico: Prophet vs GGM vs osservati
plot(anni_seq, n_host,
     type = "b", pch = 16, lty = 3, cex = 0.7, col = 1,
     xlim = c(min(anni_seq), max(anni_oos)),
     ylim = c(0, max(n_host, prophet_su_grid$nuovi_prophet) * 1.15),
     xlab = "Anno", ylab = "Nuovi host locali",
     main = "Prophet vs modelli di diffusione")

abline(v = ultimo_anno + 0.5, lty = 2, col = "grey60")

lines(anni_oos, pred_ggm, lwd = 2, col = pal_venezia[3], lty = 1)
lines(prophet_su_grid$anno, prophet_su_grid$nuovi_prophet,
      lwd = 2.5, col = pal_venezia[6], lty = 1)

legend("topright",
      legend = c("Osservati", "GGM", "Prophet"),
      col = c(1, pal_venezia[3], pal_venezia[6]),
      lty = c(NA, 1, 1),
      pch = c(16, NA, NA),
      lwd = c(NA, 2, 2.5),
      bty = "n")
```



Il confronto evidenzia le differenze di filosofia tra i due approcci. Il **GGM** produce una curva liscia, vincolata alla forma di diffusione, che estrapola in modo regolare oltre i dati. **Prophet** aderisce più fedelmente alle fluttuazioni locali grazie ai changepoint, ma la sua estrapolazione OOS dipende fortemente dall'ultimo regime di trend stimato e può risultare meno stabile su orizzonti lunghi.

In sintesi: Prophet è preferibile quando l'obiettivo è la **previsione a breve termine** e si dispone di dati ad alta frequenza con stagionalità; i modelli di diffusione restano superiori per l'**interpretazione strutturale** del processo di adozione e per le proiezioni di lungo periodo ancorate a un potenziale di mercato.

11 Conclusioni

L'analisi ha applicato una progressione di modelli di diffusione alla serie storica degli host locali Airbnb a Venezia, giungendo alle seguenti conclusioni:

1. **Il processo di adozione ha natura prevalentemente imitativa** ($p \ll q$): la crescita delle iscrizioni è stata guidata dall'effetto rete tra host già attivi, non da campagne di acquisizione esterne. Il picco si è collocato intorno al 2016–2017.
2. **Il Bass standard è un punto di partenza valido** ma soffre di una sottostima sistematica nella fase di lancio e non cattura le discontinuità indotte da shock esogeni (COVID-19, normative).
3. **I modelli GBM migliorano il fit in presenza di perturbazioni**: lo shock rettangolare è più interpretabile, quello esponenziale più flessibile ma con stime meno stabili. La scelta tra i due dipende dalla significatività dei parametri dello shock e dalla qualità dell'ACF residua.
4. **Il GGM è il candidato naturale per correggere il fit iniziale** senza introdurre artificialmente uno shock: i parametri di comunicazione p_c e q_c amplificano la curva logistica in modo endogeno.
5. **L'affinamento ARMAX riduce l'autocorrelazione residua** e produce previsioni più aderenti a breve orizzonte. Le previsioni OOS indicano una traiettoria decrescente del numero di nuovi host locali nei prossimi anni, coerente con un mercato in maturazione e con il quadro normativo crescentemente restrittivo sugli affitti brevi a Venezia.
6. **Prophet offre un controllo data-driven** complementare: ancorando la crescita logistica al potenziale m del Bass e sfruttando la frequenza mensile, individua i changepoint (in primis quello pandemico)

e una stagionalità infra-annuale invisibile ai modelli strutturali. Resta però uno strumento descrittivo-previsivo, non esplicativo: la lettura economica del fenomeno rimane affidata ai modelli di diffusione.